Activation Steering для state-based Diffusion Policy в PushT: Difference-in-Means и COAST

1 Постановка задачи

Проверяется, можно ли изменить поведение уже обученной политики, вмешиваясь в её внутренние активации во время выполнения задачи, без изменения весов. Эксперимент проводится на state-based Diffusion Policy [1] в среде PushT. Подход опирается на метод COAST [2], в котором активации успешных и неуспешных запусков используются для построения преобразования скрытых состояний политики. В оригинальной работе метод оценивался на VLA-моделях и на Diffusion Policy в среде RoboCasa. Здесь он адаптируется к более простому стенду, поэтому результаты не являются воспроизведением экспериментов статьи.

Порядок работы:

1. Запуск готовой политики и проверка её работоспособности.
2. Сбор успешных и неуспешных эпизодов.
3. Выбор слоя и извлечение его активаций.
4. Построение двух видов вмешательства.
5. Сравнение вариантов на независимом наборе начальных состояний.

Сравниваются два вида вмешательства:

- Difference-in-Means — добавление к активациям разности средних активаций успешных и неуспешных эпизодов;
- COAST-style steering — умножение активаций на матрицу, построенную по контрастивному концептору [2].

2 Базовая модель и среда

2.1 Модель

Использована реализация state-based Diffusion Policy из официального Colab-ноутбука [4] (код проекта [3]) и предобученный чекпойнт pusht_state_100ep.ckpt. Сеть предсказания шума — ConditionalUnet1D: одномерная свёрточная U-Net по оси времени последовательности действий. Наблюдения и номер шага диффузии подаются в каждый блок через FiLM-модуляцию. Обратный процесс выполняется DDPM-планировщиком (100 шагов, squaredcos_cap_v2, предсказание шума).

Параметры горизонтов:

- obs_horizon = 2 — два последних наблюдения;
- pred_horizon = 16 — длина предсказываемой последовательности;
- action_horizon = 8 — число исполняемых действий до следующего вызова политики.

Наблюдения и действия нормализуются по min-max статистикам демонстраций обучающего датасета (normalization_stats.npz). Сам датасет для обучения не используется.

2.2 Среда и критерий успеха

В PushT агент перемещает T-образный блок в целевое положение $(256, 256, \pi/4)$ в рабочей области 512×512. Наблюдение и действие:

$$o_t = [x_t^a,\, y_t^a,\, x_t^b,\, y_t^b,\, \theta_t^b], \qquad a_t = [x_t^{a,\text{target}},\, y_t^{a,\text{target}}].$$

Качество оценивается через coverage — долю площади цели, покрытую блоком. Эпизод считается успешным, если coverage превысил 0.95, и завершается досрочно. Максимальная длина эпизода 200 шагов. Награда среды является обрезанным значением $\min(1, c/0.95)$, поэтому сырое значение coverage сохраняется отдельно.

Работоспособность исходной политики проверена запуском без вмешательств, результат одного эпизода сохранён в vis.mp4.

3 Сбор эпизодов

3.1 Данные эпизода и воспроизводимость

Каждый эпизод определяется seed среды. Для воспроизводимости шума каждому вызову политики присваивается собственный seed, однозначно определяемый seed эпизода и номером вызова, чтобы исходная политика и варианты со стирингом получали одинаковый начальный шум на одинаковых начальных состояниях.

Для эпизода сохраняются: seed, метка успеха, число шагов, наблюдения, исполненные действия, reward и coverage на каждом шаге, предсказания политики и seed каждого вызова. Метка успеха формируется средой:

$$y_e = \begin{cases} 1, & \text{coverage превысил порог,} \\ 0, & \text{порог не достигнут за 200 шагов.} \end{cases}$$

Для неуспешных эпизодов число шагов до успеха записывается как -1.

Контрастивные методы требуют эпизодов обоих классов, поэтому использован чекпойнт, у которого есть как успешные, так и неуспешные эпизоды.

3.2 Наборы данных

Размеры наборов близки к протоколу COAST (15 эпизодов для построения оператора и 30 для оценки). Обучающие и тестовые seeds не пересекаются.

Таблица 1: Наборы эпизодов. Seeds ниже 200 использованы в демонстрациях обучающего датасета и не применяются.

Набор	Seeds	Эпизодов	Назначение
Обучающий	200000–200019	20	построение steering
Тестовый	300000–300034	35	оценка steering

Таблица 2: Исход обучающих эпизодов исходной политики.

Группа	Эпизодов	Доля
Успешные	5	25%
Неуспешные	15	75%
Всего	20	100%

4 Активации и выбор слоя

4.1 Извлечение

Активации перехватываются forward-хуками на выходе блоков ConditionalUnet1D. Хук только читает выход блока и не меняет архитектуру и веса. Выход блока имеет форму $H \in \mathbb{R}^{B\times C\times T}$, где C — число каналов, T — число временных позиций. Активации сохраняются на каждом из 100 шагов денойзинга при каждом вызове политики, в формате float16, без усреднения, при расчётах переводятся в float64.

4.2 Кандидатные блоки

Список кандидатов составлен по структуре сети ConditionalUnet1D и включает по одному блоку из разных её частей. В COAST также рассматривается несколько слоёв, распределённых по глубине модели с равным шагом (например, слои 0, 5, 11 и 17 из 18), после чего слой выбирается по conceptor quota. Здесь перечень кандидатов определён самостоятельно и не повторяет сетку статьи, а выбор слоя по quota выполняется по процедуре COAST. Использован выход второго residual-блока на каждом уровне: down1 (середина энкодера), mid (bottleneck), up0 (начало декодера), up1 (конец декодера).

Блок down0 не включён, так как находится близко ко входу, где сеть получает зашумлённую последовательность действий. Блок down2 почти повторяет mid по форме и положению. Выходной слой final_conv содержит предсказание шума, а не скрытое состояние. Набор является грубой сеткой кандидатов, а не доказанным оптимумом. Полный перебор блоков не проводился из-за ограничений на вычислительные ресурсы.

Таблица 3: Кандидатные блоки.

Блок	Каналы C	Позиции T
down1	512	8
mid	1024	4
up0	512	4
up1	256	8

4.3 Подготовка векторов

Для построения концепторов нужен вектор фиксированной длины. Активации усредняются по временным позициям:

$$x_c = \frac{1}{T} \sum_{j=1}^{T} H_{c,j}.$$

В COAST аналогичное усреднение выполняется по токенам действий. В ConditionalUnet1D ось T соответствует временным позициям свёрточных признаков, а не токенам, поэтому такая замена является гипотезой адаптации. Для каждого эпизода получается набор векторов длины C — по одному на каждый шаг денойзинга каждого вызова политики. Метка эпизода присваивается всем его векторам.

4.4 Выбор слоя

Слои сравниваются по quota контрастивного концептора при $\alpha = 10$:

$$q(C_{\text{steer}}) = \frac{\text{tr}(C_{\text{steer}})}{d},$$

где d — число каналов. Величина показывает долю пространства каналов, занятую концептором. По COAST слой с наибольшей quota является кандидатом для вмешательства.

Таблица 4: Quota контрастивного концептора по слоям.

Слой	Каналы	Quota
down1	512	0.065
mid	1024	0.15
up0	512	0.16
up1	256	0.12

Для вмешательства выбран слой up0 (up_modules[0][1], выход второго residual-блока первого уровня декодера).

5 Методы вмешательства

Оба метода применяются к выходу слоя up0 на всех шагах денойзинга и при всех вызовах политики (стратегия global в терминах COAST), к каждой временной позиции независимо.

5.1 Difference-in-Means

Для каждого обучающего эпизода активации усредняются по позициям, вызовам политики и шагам денойзинга, получается один вектор эпизода. Затем усредняются векторы эпизодов успешной и неуспешной групп:

$$\mu_s = \frac{1}{N_s} \sum_{i=1}^{N_s} x_i^{(s)}, \qquad \mu_f = \frac{1}{N_f} \sum_{i=1}^{N_f} x_i^{(f)}, \qquad v = \mu_s - \mu_f.$$

Каждый эпизод вносит одинаковый вклад в среднее своей группы независимо от длины. При инференсе направление добавляется к активациям:

$$h'_{b,:,t} = h_{b,:,t} + \gamma v, \qquad \gamma \in \{0.5,\ 1.0,\ 2.0\}.$$

Вектор v не нормируется: $\gamma = 1$ соответствует сдвигу на полную разность средних, $\|v\| = 1.932$. В отличие от линейного baseline из оригинальной статьи COAST, использующего нормированное направление разности средних, здесь применяется ненормированная разность средних активаций. Поэтому коэффициент γ одновременно определяет масштаб сдвига относительно исходных активаций.

5.2 COAST-style steering

Концептор. Для матрицы $X \in \mathbb{R}^{N\times d}$ векторов одной группы после центрирования $X_c = X - \mu_X$ ковариационная матрица $R = \frac{1}{N} X_c^\top X_c$, концептор

$$C = R\,(R + \alpha^{-2} I)^{-1}.$$

Расчёт выполняется через собственное разложение R в float64. Направления большой дисперсии сохраняются, малой — подавляются, а параметр α (апертура) определяет, насколько сильно. Строятся C_s и C_f для успешной и неуспешной групп.

Контрастивный концептор. Направления, характерные для успеха и отсутствующие в неуспехе, выделяются булевой операцией AND-NOT:

$$C_{\text{steer}} = \left[C_s^\dagger + (I - C_f)^\dagger - I\right]^\dagger,$$

где $\dagger$ — псевдообратная матрица.

Выбор α. Значения $\alpha \in \{0.1, 0.5, 1, 2, 10\}$ сравниваются по пересечению концепторов:

$$\text{Overlap}(C_s, C_f) = \frac{\text{tr}(C_s C_f)}{\sqrt{\text{tr}(C_s^2)\,\text{tr}(C_f^2)}}.$$

По COAST целевой диапазон [0.85, 0.95]; если ни одно значение в него не попадает, выбирается ближайшее.

Таблица 5: Overlap концепторов успеха и неуспеха на слое up0.

α	Overlap
0.1	0.8977
0.5	0.8341
1	0.8245
2	0.8266
10	0.9148

Для оценки оставлены два значения $\alpha \in \{0.1,\ 10\}$, охватывающие узкий и широкий концептор.

Применение. Матрица вмешательства

$$M = (1 - \beta) I + \beta\, C_{\text{steer}}, \qquad h'_{b,:,t} = M\, h_{b,:,t}, \qquad \beta \in \{0.1,\ 0.3\}.$$

При $\beta = 0$ активации не меняются, при $\beta = 1$ применяется полный концептор. Значения β выбраны по COAST, где малые β работали лучше больших.

6 Протокол оценки

Все варианты запускаются на одних и тех же 35 тестовых seeds с одинаковым шумом вызовов политики. Всего восемь конфигураций:

Таблица 6: Конфигурации экспериментов.

Метод	Параметры	Эпизодов
Baseline	без вмешательства	35
Difference-in-Means	$\gamma = 0.5$	35
Difference-in-Means	$\gamma = 1.0$	35
Difference-in-Means	$\gamma = 2.0$	35
COAST	$\alpha = 0.1,\ \beta = 0.1$	35
COAST	$\alpha = 0.1,\ \beta = 0.3$	35
COAST	$\alpha = 10,\ \beta = 0.1$	35
COAST	$\alpha = 10,\ \beta = 0.3$	35

Метрики для каждой конфигурации:

- Success rate — доля успешных эпизодов;
- Max coverage — среднее по эпизодам максимальное coverage, $\overline{c^{\max}} = \frac{1}{N}\sum_i \max_t c_{i,t}$;
- Steps to success — среднее число шагов до успеха среди успешных эпизодов;
- Починено / сломано — число seeds, ставших успешными / переставших быть успешными относительно baseline.

Так как у успешных эпизодов максимальное coverage ограничено порогом завершения, различия по Max coverage определяются в основном неуспешными эпизодами, а скорость решения отражает Steps to success.

7 Результаты

Метод COAST с параметрами $\alpha = 10.0, \beta = 0.1$ показал наилучший результат: success rate увеличился с 28.6% у baseline до 40.0%. Эта конфигурация также продемонстрировала наибольшее среднее покрытие среди всех рассмотренных методов (0.9253). Прирост относительно baseline составил 4 успешных эпизода (14 против 10). Метод Difference-in-Means не превзошёл baseline по количеству успешных эпизодов. При этом обе конфигурации COAST с $\beta = 0.3$ показали существенно более низкий success rate (14.3%), чем baseline (28.6%). COAST учитывает не только различие между средними активациями, но и различия в их распределениях. Это может объяснять преимущество данного метода в проведённом эксперименте, однако для проверки такого объяснения требуется дополнительный анализ преобразованных представлений.

Таблица 7: Результаты на 35 тестовых эпизодах.

Метод	Параметры	Success	Max cov.	Steps to succ.	Неудачи → успехи	Успехи → неудачи
Baseline	—	10/35 (28.6%)	0.8865	158.10	—	—
DiM	$\gamma = 0.5$	8/35 (22.9%)	0.8773	147.75	7	9
DiM	$\gamma = 1.0$	10/35 (28.6%)	0.9016	133.60	7	7
DiM	$\gamma = 2.0$	3/35 (8.6%)	0.8772	141.00	1	8
COAST	$\alpha = 0.1, \beta = 0.1$	13/35 (37.1%)	0.9176	143.62	8	5
COAST	$\alpha = 0.1, \beta = 0.3$	5/35 (14.3%)	0.7730	155.20	5	10
COAST	$\alpha = 10, \beta = 0.1$	14/35 (40.0%)	0.9253	141.86	9	5
COAST	$\alpha = 10, \beta = 0.3$	5/35 (14.3%)	0.7054	136.80	4	9

Примечание: «Неудачи → успехи» — число эпизодов, проваленных Baseline, но успешно решённых методом. «Успехи → неудачи» — число эпизодов, успешно решённых Baseline, но проваленных методом.

8 Ограничения

- Размер выборки. Операторы вмешательства строятся по 20 обучающим эпизодам, а оценка проводится на 35 тестовых. При таком размере выборки статистическая неопределённость остаётся высокой, поэтому результаты следует рассматривать как предварительные. Выводы относятся к конкретной предобученной модели и среде PushT.
- Выбор конфигурации на тестовом наборе. Все семь конфигураций оцениваются на одних и тех же тестовых seeds. Это обеспечивает сопоставимость результатов, но выбор наилучшей конфигурации по тестовой выборке может приводить к оптимистичной оценке её эффективности. Поэтому сравнение всех конфигураций приводится как исследовательский анализ, а преимущество лучшей конфигурации требует дополнительной проверки на независимом наборе начальных состояний.
- Разная агрегация данных. В Difference-in-Means сначала усредняются векторы внутри эпизода, поэтому каждый эпизод имеет одинаковый вес. В COAST все векторы активаций объединяются без весов, и более длинные эпизоды вносят больше наблюдений в оценку ковариации. Кроме того, активации, полученные на соседних шагах денойзинга и вызовах политики, не являются независимыми наблюдениями. Поэтому большое число векторов активаций не эквивалентно большому числу независимых эпизодов. Методы различаются не только формулой вмешательства, но и способом подготовки данных.
- Глобальное применение steering. Вмешательство применялось на всех 100 шагах денойзинга с использованием одного и того же оператора. Однако вклад различных этапов денойзинга в формирование итоговой траектории может различаться. В работе не исследовались альтернативные стратегии, ограничивающие вмешательство отдельными временными интервалами или первыми k шагами денойзинга.
- Выбор слоя. Рассмотрены четыре блока, перебор всех блоков не проводился.

9 Реализация

Среда PushT, сеть ConditionalUnet1D, DDPM-планировщик и цикл инференса взяты из Colab-ноутбука Diffusion Policy [4] с изменениями: добавлено сохранение сырого coverage,

воспроизводимый шум для каждого вызова политики, сохранение активаций и вмешательство через forward-хуки. Реализация концепторов, контрастивной операции AND-NOT и мультипликативного гейта выполнена по описанию и псевдокоду из приложения статьи COAST [2]; код авторов не использовался.

Эксперименты выполнены на виртуальной машине: Ubuntu 22.04, Python 3.10.12, PyTorch 1.13.1+cu117, NumPy 1.24.4, scikit-image 0.19.3, NVIDIA A10 (24 ГБ).

Сохраняемые данные: параметры и версии (metadata.json), эпизоды (steering_train_act_*.pkl, baseline_test_*.pkl), активации (activations/), статистики нормализации (normalization_stats.npz) и результаты оценки (results_*.pkl). Результаты записываются после каждого эпизода через временный файл с атомарной заменой, что позволяет продолжать эксперимент после прерывания.

10 Заключение

В работе реализовано вмешательство в скрытые представления предобученной state-based Diffusion Policy в среде PushT без изменения весов модели. Для построения операторов steering собраны успешные и неуспешные эпизоды, извлечены активации четырёх residual-блоков U-Net и выбран слой up0 по критерию conceptor quota. Сравнение показало, что наилучший результат среди рассмотренных конфигураций достигнут методом COAST при $\alpha = 10, \beta = 0.1$: success rate составил 40.0% против 28.6% у baseline, а среднее максимальное покрытие увеличилось с 0.8865 до 0.9253. Метод Difference-in-Means не превзошёл baseline по количеству успешных эпизодов, а увеличение силы вмешательства COAST до $\beta = 0.3$ сопровождалось снижением success rate. Несмотря на то что тестовые эпизоды не использовались при построении операторов вмешательства, выбор лучшей конфигурации выполнялся по результатам на этом же наборе. Поэтому полученное преимущество требует дополнительной проверки на новом наборе начальных состояний. Качественно полученные результаты согласуются с выводами авторов COAST, нелинейное вмешательство оказалось эффективнее линейного сдвига средних.

Список литературы

[1] C. Chi, Z. Xu, S. Feng, E. Cousineau, Y. Du, B. Burchfiel, R. Tedrake, S. Song. Diffusion Policy: Visuomotor Policy Learning via Action Diffusion. Robotics: Science and Systems, 2023. https://arxiv.org/abs/2303.04137

[2] M. M. Miao, S. Kim, B. Yang, L. Ungar. Contrastive Conceptor Activation Steering (COAST): Unlocking Vision-Language-Action Models through Hidden States. arXiv preprint arXiv:2605.17144, 2026. https://arxiv.org/abs/2605.17144

[3] Репозиторий Diffusion Policy (real-stanford). https://github.com/real-stanford/diffusion_policy

[4] Google Colab: state-based Diffusion Policy для PushT. https://colab.research.google.com/drive/1gxdkgRVfM55zihY9TFLja97cSVZOZq2B?usp=sharing